

Learning PAC

Andres J. Montenegro Bello*

GitHub : AndresJuniorMontenegro

Raul Huaman Pajares †

GitHub : rhuamanpa

Repositorio

<https://github.com/rhuamanpa/Pac-Learning>

ABSTRACT

We will analyze PAC learning, the type of uses that we can apply with PAC learning with machine learning and show some samples used by big companies like Facebook and Youtube to make incomes at the same time we will make a project using PAC learning using python that will recognize some facial gestures.

1 INTRODUCTION

La probabilidad aproximada correcta (PAC), propuesta por L. Valiant, es un marco de referencia estatico para aprender usar datos de entrenamiento.

En su forma mas simple y para un modelo tipico de tarea, la teoria del aprendizaje PAC intentan relacionar, precision y confianza estadistica del modelo al numero de ejemplos de entrenamientos usados.

Uno de los conceptos más importantes en este sentido es medir la complejidad de una clase de hipótesis H . En cualquier modelo de aprendizaje automático, el objetivo final es encontrar una clase de hipótesis que logre una alta precisión en el conjunto de entrenamiento y que tenga un bajo error de generalización en el conjunto de prueba. Para esto, requerimos que la clase de hipótesis H se aproxime al concepto de clase C que determina las etiquetas para la distribución D . Como tanto C como D son desconocidos, tratamos de modelar H en base al conjunto de muestras conocido S y sus etiquetas.

Generalizacion del error: El error de generalización de una hipótesis h es la expectativa del error en una muestra x elegida de la distribución D .

Error empirico: Esta es la media del error de la hipótesis h en la muestra S del tamaño m .

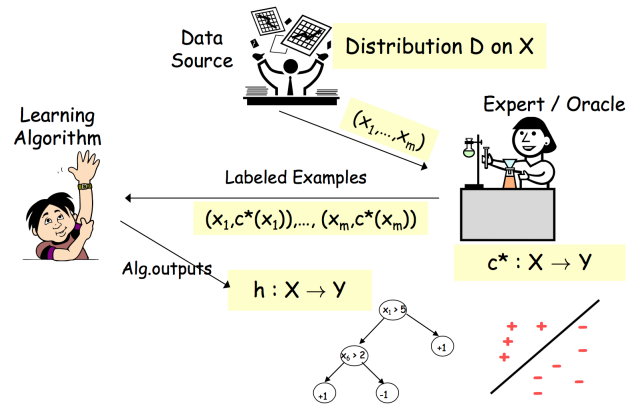
Habiendo definido el error de generalización y el error empírico de esta manera, podemos establecer el objetivo del aprendizaje de la siguiente manera.

El objetivo del aprendizaje es tener el error empírico aproximado al error de generalización con alta probabilidad.

Este tipo de marco de aprendizaje se conoce como Aprendizaje PAC (Probablemente Aproximadamente Correcto). Formalmente, una clase de concepto C es PAC – *aprendible* si hay algún algoritmo A para el cual el error de generalización en una muestra S derivado de la distribución D es muy bajo (menor que ϵ) con alta probabilidad (mayor que $1 - \delta$). En otras palabras, podemos decir que para una clase apta para PAC, la precisión es alta con buena confianza.

Se adjuntara una imagen en la cual dara una descripcion general del aprendizaje PAC.

PAC/SLT models for Supervised Learning



2 ESTADO DEL ARTE

El aprendizaje PAC(aprendizaje correcto probablemente aproximado) como su nombre lo dice generara probables situaciones para dar un resultado correcto aproximado, esta ciencia es una similitud o podemos decir una rama del machine learning y el deep learning, sus usos son muy dinamicos y eficaces, actualmente se utiliza como herramienta muy util veamos 3 ejemplos:

Identificación de temas: Clasificación multi-etiqueta de medio de artículos impresos deducido de una base de datos.

La data fue recolectada desde el Mayo del 2013 hasta Setiembre del 2013,

Los articulos fueron manualmente segmentados.

El texto de los articulos es representado usando "Una mochila de palabras modelo".

Esta base de datos cuenta con 301561 atributos numericos, 213 tipo de etiqueta y 99780 articulos, los cuales 64857 fueron data de entrenamiento y 34923 fueron data de prueba, el objetivo es predecir las etiquetas relevantes del conjunto de data de prueba.

Se adjunta el link del conjunto de data:

<https://www.kaggle.com/c/wise-2014/data>

Recomendación de películas: Sistema utilizado para predecir la afluencia que tendra una pelicula y su calificacion global, determinada por la calificacion previa a peliculas con similar caracteristica o etiqueta sacada de una base de datos ya sea de Netflix o Movie Lens

Se adjuntara los links de la base de datos de dichas plataformas de películas:

Netflix:

<https://www.netflixprize.com/leaderboard.html>

*e-mail: montenegroandresj@gmail.com

†e-mail: rahuamanpa@gmail.com

Movie Lens:
<https://grouplens.org/datasets/movielens/>

Video resumen: Selecciona semanticamente las partes más importantes de un video debido a una base de datos muy grande de metricas en la plataforma de *YOUTUBE*, esto es usado como grandes compañías como *Facebook* y *Youtube*, para que puedan insertar la publicidad en las partes mas relevantes del video subido y asi más probabilidad de que puedan ver la publicidad.

Se adjunta la data de *Youtube* y es :

<https://research.google.com/youtube8m/index.html>

3 DISEÑO DEL EXPERIMENTO

Se diseñara un experimento en la cual se capturara una imagen y este reconocera ciertos gestos faciales.

Debido a un conjunto de patrones establecidos.

Se implementara con el lenguaje de programación *Python*.

4 EXPERIMENTOS Y RESULTADOS

- Para realizar el reconocimiento facial se usara el lenguaje de programación *Python*.
- Se usara extensiones a ciertas librerias como:
 - Libreria OpenCV
 - Libreria Numpy
 - Libreria PIL
 - Libreria Pickle

4.1 Primera etapa

- Para empezar el experimento al instalar la libreria OpenCV, esta misma libreria nos proporciona de una data para aplicar el reconocimiento de los rostros que se llama **harcascade_frontalface_alt2.xml**
- El proceso del experimento requerrira de dos ficheros donde uno de ellos es para el entrenamiento y el otro usara el entrenamiento para aplicar el reconocimiento facial.
- Empezaremos el codigo primero con tener el control de la camara de video de la Laptop en este caso.

```
import cv2

cap = cv2.VideoCapture(0)

while (True):

    #Capturar frame por frame
    ret, frame = cap.read()

    #Mostrando los frames resultantes
    cv2.imshow('frame', frame)

    if cv2.waitKey(20) & 0xFF==ord('q'):
        break

cap.release()
cv2.destroyAllWindows()
```

- Una vez que se pudo tener la captura de video pasariamos a usar la data que nos proporciona la libreria OpenCV

```
face_cascade = cv2.CascadeClassifier("cascade/
data/harcascade_frontalface_alt2.xml")
```

- Una vez utilizando la data que nos da la libreria OpenCV, seguimos a pasar los **frame** capturados a escala de color gris.

```
gray = cv2.cvtColor(frame, cv2.COLOR_BGR2GRAY)
```

- Luego se procede a reconocer la existencia de rostros

```
faces = face_cascade.detectMultiScale(gray,
scaleFactor=1.5, minNeighbors=5)
```

- Despues dibujariamos un rectangulo en el rostro reconocido, y en la libreria OpenCV utiliza los colores de forma BGR (Blue, Green, Red) y no la forma tradicional RGB.

```
for (x,y,w,h) in faces:
    color = (255,0,0)
    stroke = 2
    end_cord_x = x+w
    end_cord_y = y+h
    cv2.rectangle(frame,(x,y),
    (end_cord_x,end_cord_y),
    color,stroke)
```

- Con todo estos pasos se puede reconocer rostros gracias a la libreria OpenCV y a la data que ofrece para reconocer rostros.
- El fichero de todo esto se encuentra con el nombre de **captura_rostro.py**




Figure 1: Prueba de reconocimiento de rostro

4.2 Segunda etapa

- Lo que sigue, es ahora crear una pequeña base de datos de imagenes, en este caso usaremos imagenes de personajes de una serie quienes son:
 - Harvey Specter
 - Donna
 - Michael Ross
- De cada personaje usamos 6 imagenes que se encuentra en carpetas que son sus respectivos nombres.
- Para empezar el entrenamiento tenemos que referenciar sus ubicaciones absolutas de todas las fotos que usaremos para hacer la prueba.

```
#Obtener las direcciones absoluta del
#directorio del fichero
BASE_DIR = os.path.dirname(
    os.path.abspath(__file__))

#Dentro de ese fichero hay una carpeta
#images y ahí están las imágenes de los
#personajes

image_dir = os.path.join(BASE_DIR,"images")
```

- Después de ello extraemos todas las direcciones absolutas de todas las imágenes de los personajes.

```
for root,dirs,files in os.walk(image_dir):
    for file in files:
        if file.endswith(".png") or
           file.endswith(".jpg"):
            path = os.path.join(root, file)
            label = os.path.basename(root).
                replace(" ", "-").lower()
```

- Convertimos a escala grises todas las imágenes de los personajes con la librería PIL y lo guardamos en un array de imágenes.

```
#Escala grises
pil_image = Image.open(path).convert("L")
image_array = np.array(pil_image,"uint8")
```

- Lo mismo que en la primera etapa usaremos la data de OpenCV nos ofrece para reconocer los rostros de las imágenes de los personajes seleccionados.

```
face_cascade = cv2.CascadeClassifier("
    cascade/data/haarcascade_frontalface
    _alt2.xml")
```

- Después con todas las imágenes dentro de image_array se seguirá con los rostros detectados en dichas imágenes.

```
faces = face_cascade.detectMultiScale(
    image_array, scaleFactor=1.5,
    minNeighbors=5)
```

- Después se guarda los rostros reconocidos en un vector **x_train** y su etiqueta en **y_labels**.

```
for (x,y,w,h) in faces:
    roi = image_array[y:y+h, x:x+w]
    x_train.append(roi)
    y_labels.append(id_)
```

- Por último exportamos dos archivos.

- El primer archivo es para las etiquetas de cada carpeta de fotos, que en otras palabras sería el nombre del personaje con su respectiva foto y este archivo se llama **labels.pickle**

- El segundo archivo es aquel que sirva para el entrenamiento y así poder reconocer los rostros de los personajes seleccionados y este archivo se llama **trainer.yml**

- El archivo de entrenamiento de rostros se llama **entrenamiento_rostros.py**




Figure 2: Ficheros de entrenamiento

4.3 Tercera etapa

- Una vez teniendo los archivos de entrenamiento ahora haremos los cambios respectivos para el fichero de la primera etapa.

- Se crea un variable que extraiga la información del archivo "trainer.yml" ya que es el archivo para que reconozca a los personajes escogidos previamente.

```
recognizer = cv2.face.LBPHFace
    Recognizer_create()

recognizer.read("trainer.yml")
```

- Luego se captura las etiquetas o nombres de los personajes escogidos del archivo "labels.pickle" para que me arroje el nombre del rostro de dicho personaje.

```
with open ("labels.pickle",'rb') as f:

    og_labels = pickle.load(f)

    labels = {v:k for k,v in
        og_labels.items() }
```

- Por último imprimimos con una confiabilidad de 50% o más.

```
id_, conf = recognizer.predict(roi_gray)

if conf>= 50:
    print(id_)
    print(labels[id_])
```

- El fichero de reconocer rostros de personajes se llama **reconocimiento_rostro.py**

- En las próximas fotos se aprecia abajo de la foto que muestra el nombre del personaje escogido, por lo que hay buen reconocimiento de rostro.

- Una mejora a todo esto es dando más imágenes de los personajes ya que solo hemos puesto 6 de cada uno y si estas imágenes aumentan habrá una mejor confiabilidad de respuesta.

- Y también al poner una cámara de mejor calidad, eso ayudaría a que los frames se puedan hacer una mejor escala grises y así poder lograr una mejor captura de video y dar más confiabilidad en todo ello.

- Mostrando los resultados.

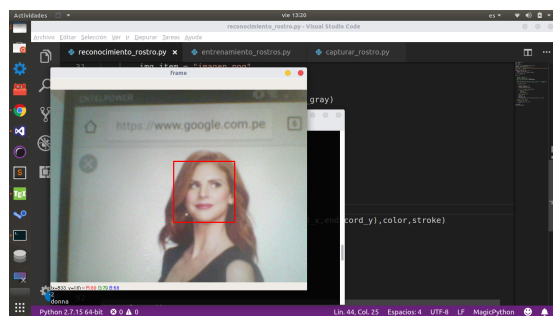


Figure 3: Prueba con el personaje Donna

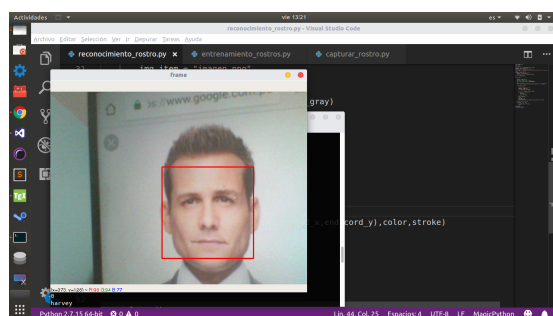


Figure 4: Prueba con el personaje Harvey

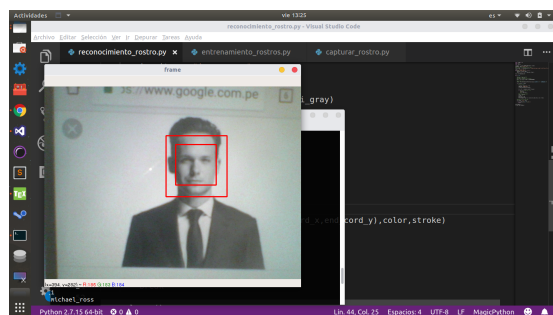


Figure 5: Prueba con el personaje Michael Ross